



北京大学

第一讲 课程简介、自然语言理解简史与文本预处理

基于深度学习的自然语言理解

邓志鸿

2024年9月13日星期五



- 课程简介
- 自然语言理解简史
- 文本预处理

- 主讲教师

- 邓志鸿

- ✓ 办公室：理科2号楼2318

- ✓ Email: zhdeng@pku.edu.cn

- 助教

- 项昱然

- ✓ 2401112153@stu.pku.edu.cn

- 吴宇桐

- ✓ 1020030609@qq.com

- 时间

- 1-16周

- ✓每周：周五 7-8节 (15:10-17:00)

- 地点

- 一教308

- 课程网站

- <https://course.pku.edu.cn/>

- 基于深度学习的自然语言理解

群聊：基于DL的NLP24秋课程
群



该二维码7天内(9月20日前)有效，重新进入将更新

- 教材
 - 无
- 参考书
 - 《Speech and Language Processing》 (Daniel Jurafsky and James H. Martin)
✓ <https://probml.github.io/pml-book/book1.html>
 - 《Dive into Deep Learning》 (Aston Zhang, Z. C. Lipton, Mu Li and A. J. Smola)
✓ <https://d2l.ai/>
- 参考教程
 - Natural Language Processing with Deep Learning (Stanford CS 224N)
✓ <https://web.stanford.edu/class/cs224n/index.html>
 - Natural Language Processing (Princeton COS 484)
✓ <https://nlp.cs.princeton.edu/cos484/>

要想及时了解和学习到自然语言理解和处理方面的最新概念与方法、最前沿技术和最新发展动态，以下渠道是不可或缺的

- 国际相关顶级会议
 - ACL, EMNLP, NAACL
 - ICLR, ICML, NeurIPS
 - AAAI, IJCAI
 - 微信公众号
 - 博客、Blog
- } 课程微信群会转发这些平台上的最新报道

- 国外NLP资源

- ✓斯坦福软件工具: <https://nlp.stanford.edu/software/>

- 中文资源

- ✓<https://github.com/InsaneLife/ChineseNLPCorpus>

- 中文NLP软件工具

- 各类中文语料库

- 文心一言

- ✓<https://yiyan.baidu.com/>

- 通义千问（阿里巴巴）

- ✓<https://tongyi.aliyun.com/>

- 讯飞星火（科大讯飞）

- ✓<https://xinghuo.xfyun.cn/>

- 智谱清言（智谱AI）

- ✓<https://xinghuo.xfyun.cn/>

- Deepseek

- ✓<https://www.deepseek.com/>

- kimi

- ✓<https://kimi.moonshot.cn/>

- ChatGPT

- ✓<https://openai.com/>

- Claude

- ✓<https://www.anthropic.com/claude>


- Le Chat

- ✓<https://mistral.ai/>

- 数学（基础理论）
 - ✓ 高等数学基础知识（微分）
 - ✓ 线性代数基础知识（向量、矩阵）
 - ✓ 概率基础知识（概率、条件概率等）
- 编程（工程实现）
 - ✓ Pytorch
 - ✓ 其他任何编程语言和平台
- 机器学习概论（模型算法，非必要）
 - ✓ 学过有助于理解本课程，学习起来相对容易
 - ✓ 没学过也可以，本课程自成体系，有机器学习基础的内容（围绕自然语言理解来讲授）

- 帮助同学掌握以深度学习技术为工具的自然语言理解所涉及的基本理论、关键模型、核心算法和前沿技术
 - ✓问题背景
 - ✓建模
 - ✓算法
- 增强同学理论结合实践、学以致用能力
 - ✓不仅仅会用，而且能用的更好
 - ✓算法和应用创新

- 团队任务考核 (50%)
 - ✓ 团体任务 (2人左右)
 - ✓ 课程项目 (50%)
 - 项目内容 (PPT内容) : 35%
 - 项目报告 (PPT讲解) : 15%
- 个人任务考核 (50%)
 - ✓ 论文研读报告及课后小练习 (20%)
 - ✓ 课程论文 (30%, 每位同学单独提交一篇)

A large, multi-pointed pink starburst graphic that serves as a background for the bonus text.

额外奖励 (5分)
课堂表现、微
信群交互、课
程建议等

- 政策
 - ✓ 2人左右组成团队
 - ✓ 每个团队独立完成前沿技术报告和课程项目
 - ✓ 鼓励讨论，严禁抄袭
- 时间节点
 - ✓ 2024年9月27日前完成组队，并向**项昱然助教**提交名单
 - 团队名称
 - 队长和成员名单（含学号）
 - ✓ 如未完成，由任课老师安排组队

- 选题（四选一）

- ✓ 对对联、写古诗等（课程提供的选题，有模板可参考，报告时要现场演示）
- ✓ 复现自然语言处理相关顶级会议论文所提的算法，并进行实验分析和讨论，最好能有自己的创新
- ✓ 参见自然语言处理相关的国内外比赛
- ✓ 自己构思一个自然语言相关的项目

- 截止日期

- ✓ 项目题目及摘要：2024年 11月1日
- ✓ 项目课堂报告安排：本学期最后一周
- ✓ 相关资料（PPT和源码）：2024年12月23日

注意：同一团队所有同学都要参与项目报告，要求每位成员报告其中一部分。并且报告中要明确每位成员的分工

提交给**项昱然助教**


- 研读论文列表发布
 - ✓ 2024年10月11日
 - ✓ 可选非列表中的论文（必须与自然语言处理相关）进行研读并报告，在2024年11月1日前提出并把论文发给**吴宇桐助教**
 - ✓ 确定论文截止日：2024年11月1日
- 报告安排
 - ✓ 等后续通知，大概在2024年11月上旬

- 要求
 - ✓包含题目、摘要、以数字标识节和小节、参考文献（数字或作者姓氏排序）
 - ✓至少2000字
 - ✓内容（三选一）
 - 已有或自创模型/方法的实现与实验分析
 - 相关前沿技术方向的综述、分析和总结
 - 对现有大模型带独立思考的评述
- 截止日期
 - ✓2025年1月15日
- 课程论文提交给**吴宇桐**助教

- 课程简介、文本预处理
- N-gram语言模型
- 神经语言模型
- 向量语义与词嵌入
- 循环神经网络
- 条件语言模型、Seq2Seq与注意力机制
- 自注意力与Transformer
- 预训练语言模型
 - ✓ELMo、BERT、T5、GPT 1-4
- 参数高效微调方法
 - ✓Prefix Tuning, Prompt Tuning, P-Tuning
 - ✓Adapter Tuning, LoRA, FACT
- In-Context Learning
- ChatGPT
- 多模态神经语言模型

以及上述模型或方法在文本生成、机器翻译、情感分类、自然语言推理、问答系统、对话系统等下游任务的应用


文本生成、机器翻译、自动问答、对话、文本摘要、文本/情感分类、文本推理、...




- 课程简介
- 自然语言理解简史
- 文本预处理


- 人工智能的目标之一是实现机器能理解人类语言，从而达到人机无缝交流的目的
- 通过理解语言，可以完成以下任务
 - ✓ 人机对话
 - ✓ 问答
 - ✓ 翻译
 - ✓ 自动摘要
 - ✓ 情感分析
 - ✓ 写作
 - ✓ ...

图灵测试：通过人类和机器之间的自然语言对话来判断机器是否具有智能



- 从自然语言处理发展的四个时代了解自然语言理解的历史
 - ✓ 第一时代 (1950-1969)
 - 最早始于机器翻译的研究，只提供单词级的翻译查找和简单的规则机制
 - ✓ 第二时代 (1970-1992)
 - 语言学和基于知识的人工智能正在迅速发展，出现了新一代手工构建的系统
 - ✓ 第三时代 (1993-2012)
 - NLP的发展逐渐转为深度的语言理解，围绕词开展有监督机器学习技术来构建模型
 - ✓ 第四时代 (2013-现在)
 - 随着深度学习方法的引入，可以对长距离的上下文进行建模。特别是基于自监督学习方法的预训练语言模型/大语言模型带来了变革性的影响，使得自然语言理解 and 处理进入了新的阶段





2018年: BERT 2019年: T5 2020年: GPT 3 2022年: ChatGPT 2023年: GPT-4

Google Translate

CHINESE - DETECTED

ENGLISH

SPANISH

FRENCH



今天的北京大学已经成为国家培养高素质、创造性人才的摇篮、科学研
究的前沿和知识创新的重要基地和国际交流的重要桥梁和窗口。|

Jīntiān de běijīng dàxué yǐjīng chéngwéi guójiā péiyǎng gāo sùzhì, chuàngzàoxìng réncái
de yáolán, kēxué yánjiū de qiányán hé zhīshì chuàngxīn de zhòngyào jīdì hé guójì jiāoliú
de zhòngyào qiáoliáng hé chuāngkǒu.



59 / 5000



ENGLISH

SPANISH

ARABIC



Today, Peking University has become the country's cradle for
cultivating high-quality and creative talents, an important base for
scientific research and knowledge innovation, and an important bridge
and window for international exchanges.






应用：诗歌创作




信手折枝堪作笔



随心对月可成诗

凭栏寄语乡音远



把盏吟诗客梦长

嫩枝粉蕾三分俏



细柳红花一处香

输入：春 处 夜 花


AI输出：
春风吹雨霏，处处不堪悲。
夜夜深声睡，花开小院垂。

春晓

[唐] 孟浩然

春眠不觉晓，处处闻啼鸟。

夜来风雨声，花落知多少。



a car is parked in the middle of nowhere .



a wooden table and chairs arranged in a room .



there is a cat sitting on a shelf .



a little boy with a bunch of friends on the street .



a ferry boat on a marina with a group of people .

看图说话

跨模态检索

Nearest Images



- day + night =

- flying + sailing =

- bowl + box =

- box + bowl =





输入：席地而坐看星空的小孩和小狗

输出：



文生图

ChatGPT



What NLP topics should I teach in 2023?



Here are some NLP topics that are popular and relevant in 2023:



1. Transformers (BERT, GPT, etc.)
2. Transfer Learning in NLP
3. Multi-lingual NLP
4. Attention Mechanisms
5. Adversarial Training in NLP
6. NLP for Question Answering
7. Sentiment Analysis
8. Text Generation (summarization, translation, etc.)
9. Named Entity Recognition
10. Dialogue Systems

Note: The field of NLP is constantly evolving, so it's important to stay up-to-date with recent advances and adjust your teaching content accordingly.

in-context learning

Model Input

Q: Roger has 5 tennis balls. He buys 2 more cans of tennis balls. Each can has 3 tennis balls. How many tennis balls does he have now?

A: Roger started with 5 balls. 2 cans of 3 tennis balls each is 6 tennis balls. $5 + 6 = 11$. The answer is 11.

Q: The cafeteria had 23 apples. If they used 20 to make lunch and bought 6 more, how many apples do they have?

Model Output

A: The cafeteria had 23 apples originally. They used 20 to make lunch. So they had $23 - 20 = 3$. They bought 6 more apples, so they have $3 + 6 = 9$. The answer is 9. ✓

User

What is unusual about this image?

GPT-4

Source: <https://www.barnorama.com/wp-content/uploads/2016/12/03-Confusing-Pictures.jpg>

GPT-4

The unusual thing about this image is that a man is ironing clothes on an ironing board attached to the roof of a moving taxi.

- 课程简介
- 自然语言理解简史
- 文本预处理

- 目标
 - ✓把文本转化成机器容易处理的标准形式
- 技术
 - ✓文本规范化 (Text Normalization)
 - 分词 (tokenizing words or segmenting words)
 - 规范词格式 (normalizing word formats)
 - 切分句子 (segmenting sentences)
 - ✓编辑距离 (Edit Distance)

- 在对文本进行自然语言分析、理解和处理前，必须按照一定的要求把文本中的句子、段落切分成一个字符串序列
 - ✓ 字符串序列中的元素称为token（中文也称词语，词元等）。Token可以理解为文本中的最小语义单元（或基本单位）。Token可以是词、字词、字、甚至是字母
 - ✓ 在本课程中，为讨论和理解方便，统一用词来表述token
- 把文本变成token序列的过程，称为tokenization，即分词。分词是自然语言理解或处理的基础任务，是后续一切处理的基础
 - ✓ 例子
 - 我喜欢基于深度学习的自然语言理解课程
 - 我 / 喜欢 / 基于 / 深度学习 / 的 / 自然语言理解 / 课程

- 按照切分的粒度，分词可分为三类

- ✓ 字符粒度 (character)

- 按照语言的最小符号单位进行切分，很简单
- 缺点：丢失词汇的语义信息和边界信息，输入变成长
- 优点：词汇表大大缩减，26个字母基本能覆盖所有英文单词，5000多个中文字也能基本覆盖中文词汇，而且不受现有词汇量的限制。由于中文中的字一定的语义信息，而且具有以上优点，目前研究表明基于字切分的中文自然语言处理新能更好

- ✓ 词粒度 (word)

- 类似人对自然语言文本的理解方式，非常自然
- 对于英文等西方语言，词粒度相对简单，通过空格作为分隔符即可进行切分。但对于中文等亚洲语言，由于文字间没有空格，容易造成歧义现象，使得分词变得很困难

- ✓ 子词粒度 (subword)

- 一种处于字符粒度和词粒度之间的折中方法，适用于英文等西方语言
- 对中文而言不合适，应为中文不适合把字拆分成偏旁部首和字根
- 代表性方法：BPE

- 识别空格或标点符号（作为词的分隔符）是否足够？
- 特殊处理
 - ✓ 数字 (Numbers)
 - 无上下文环境，语义模糊
 - 510B.C.
 - ✓ 连字符 (hyphen)
 - state-of-the-art → state of the art
 - B-2A (一种轰炸机) → B 2A
 - ✓ 标点符号 (punctuation)
 - U.S.A.
 - Dr.
 - ✓ 大小写字母 (lower or upper letters)
 - General Motors : general motors
 - apple : Apple : APPLE

- 背景
 - ✓ 汉语的书面语是按句分开的，词与词之间没有明确的分隔标记
 - ✓ 词是具有独立意义的基本语言单位，中文理解从词开始
- 意义
 - ✓ 后续中文理解和应用的基础
- 挑战
 - ✓ 歧义
 - ✓ 未登入词
- 传统方法
 - ✓ 前（后）向最大匹配分词法
 - ✓ 最短路径分词法
 - ✓ 基于统计词频分词法
- 现代方法：基于深度学习的分词法
 - ✓ 注意：在现代以深度学习为工具的自然语言理解和处理中，其实不用分词，用字作为处理的基本单位就可以（效果还更好）

- 交叉歧义

- ✓如果AB和BC都是词，那么切分ABC时，造成两种可能的切分

- “AB | C”

- “A | BC”

- ✓结合成分子时

- 组合歧义

- ✓如果AB、A和B都是词，那么切分AB时，造成两种可能的切分

- “AB”

- “A | B”

- ✓这个**人手**上有痣

- 真歧义

- ✓乒乓球**拍卖**完了


- ✓她**真好**说话

- ✓**人才**是海淀最美丽的风景

- 未登录词又称为生词 (unknown word) , 可以有两种解释
 - ✓ 一是指已有的词表中没有收录的词
 - ✓ 二是指已有的训练语料中未曾出现过的词。在这种解释下, 未登录词又称为集外词 (out of vocabulary, OOV) , 即训练集以外的词
 - ✓ 例子: 克林顿对内塔尼亚**胡说**
- 类型
 - ✓ 中外人名、地名
 - 特朗普、拜登、布鲁克菲尔德
 - ✓ 组织机构名称和商标
 - 世界贸易组织、华为、腾讯、微信、阿里、百度
 - ✓ 专业术语
 - 统计语言模型、神经语言模型、预训练语言模型、语言大模型



网络用语
请举例



S1 = “我喜欢基于深度学习的自然语言理解课程”

最大词长MaxLen = 6

S2 = “ ”

词典

...
深度学习
课程
我
喜欢
我们
自然语言理解
...

S1 = “我喜欢基于深度学习的自然语言理解课程”

1. 从S1左边取出候选子串W = “我喜欢基于深”
2. 查词典，发现“我喜欢基于深”不在词典中，删除W最右边的字“深”后，W = “我喜欢基于”
3. 查词典，发现“我喜欢基于”不在词典中，删除W最右边的字“于”后，W = “我喜欢基”
4. 查词典，发现“我喜欢基”不在词典中，删除W最右边的字“基”后，W = “我喜欢”
5. 查词典，发现“我喜欢”不在词典中，删除W最右边的字“欢”后，W = “我喜”
6. 查词典，发现“我喜”不在词典中，删除W最右边的字“喜”后，W = “我”
7. 查字典，发现“我”在词典中，输出“我”到结果集S2，置S1 = “喜欢基于深度学习的自然语言理解课程”

词典

...
深度学习
课程
我
喜欢
我们
自然语言理解
...

S1="喜欢基于深度学习的自然语言理解课程"

重复Step 2 - Step 7, 输出 "喜欢"

S1="基于深度学习的自然语言理解课程"

重复Step 2 - Step 7, 输出 "基于"

S1="深度学习的自然语言理解课程"

重复Step 2 - Step 7, 输出 "深度学习"

.....

S2= "我\喜欢\基于\深度学习\的\自然语言理解\课程"

词典

...

深度学习

课程

我

喜欢

我们

自然语言理解

...


- 最大词长 (MaxLen)
 - ✓ 过短
 - 长词会被切分错了, 如 “中华人民共和国外交部”
 - ✓ 过长
 - 效率低下, 需要排除太多的非词
 - ✓ 思考: 是否可以设计自适应变长的算法
- 歧义
 - ✓ 结合成分子时 → 结合 成分 子时
- 词典
 - ✓ 滞后性

- 基本思想


- ✓ 首先将句子中所有字都切分开来，根据词表将组成词的字连接起来，构成“词图”

- ✓ 然后求解“词图”的最短路径就是分词结果

- 词图中的路径上的数字“1”代表权重，这里我们全部取为1，代表每种分词的重要性。然后利用 N-最短路径或者 Dijkstra 算法便可以求解出最短路径




- 最短路径分词法简化边的权重为1，但不符合常识。因为词出现的频率分布不一样，为此，用词出现的条件概率作为边权重更为合理。这样解“词图”最短路径的方法转为求解概率最大路径（带权重的最短路径）。这就是基于统计词频分词法



转化成一个分类模型

通过字的上下文预测该字的标签



结合成分子时 → 标记

标签集合 $T = \{B, M, E, S\}$

B : 表示对应的字是词的开始

M : 表示对应的字是词的中间

E : 表示对应的字是词的结束

S : 表示对应的字是一个词

结合成分子时
 $B E S B E S$

形成

语料库

$B \quad M \quad E \quad S$
0.3 0.2 0.1 0.6

训练目标:

正确标签的预测概率最大化


- Byte Pair Encoding（字节对编码），是当前基于深度学习的自然语言处理（英文等）常用的分词方法
- 即不通过空格切文本，也不通过字符切分文本，而是通过数据本身来决定如何切分
 - ✓ 通常用规则或机器学习的方法
- 算法步骤
 1. 初始化词表：将每个字符看作一个词，构建初始的词表
 2. 统计频次：统计每个字符组合（包括字符本身）在文本中出现的频次
 3. 合并最频繁的字符组合：选择出现频次最高的一对字符组合，将它们合并成一个新的字符，并更新词表
 4. 重复步骤2和步骤3，直到达到预设的词表大小或者不再有字符组合可以合并

corpus

5 l o w _
2 l o w e s t _
6 n e w e r _
3 w i d e r _
2 n e w _

vocabulary

_, d, e, i, l, n, o, r, s, t, w



单词结束符

Merge **e r** to **er**

corpus

5 l o w _
2 l o w e s t _
6 n e w e r _
3 w i d e r _
2 n e w _

vocabulary

_, d, e, i, l, n, o, r, s, t, w, er

corpus

5 l o w _
 2 l o w e s t _
 6 n e w e r _
 3 w i d e r _
 2 n e w _

vocabulary

_, d, e, i, l, n, o, r, s, t, w, e r

Merge **er _** to **er_**

corpus

5 l o w _
 2 l o w e s t _
 6 n e w e r_
 3 w i d e r_
 2 n e w _

vocabulary

, d, e, i, l, n, o, r, s, t, w, e r, e r

corpus

5 l o w _

2 l o w e s t _

6 n e w er__

3 w i d er__

2 n e w _

vocabulary

_, d, e, i, l, n, o, r, s, t, w, er, er__

Merge **n e** to **ne****corpus**

5 l o w _

2 l o w e s t _

6 ne w er__

3 w i d er__

2 ne w _

vocabulary

_, d, e, i, l, n, o, r, s, t, w, er, er__, ne

重复合并，结果如下

Merge	Current Vocabulary
(ne, w)	—, d, e, i, l, n, o, r, s, t, w, er, er—, ne, new
(l, o)	—, d, e, i, l, n, o, r, s, t, w, er, er—, ne, new, lo
(lo, w)	—, d, e, i, l, n, o, r, s, t, w, er, er—, ne, new, lo, low
(new, er—)	—, d, e, i, l, n, o, r, s, t, w, er, er—, ne, new, lo, low, newer—
(low, —)	—, d, e, i, l, n, o, r, s, t, w, er, er—, ne, new, lo, low, newer—, low—

- 从例子可以看出，BPR生成的词汇表具有以下特点
 - ✓ 通常包含频次高的词和子词
 - ✓ 子词通常是est, er等语素（morphemes）
- 语素是语言中最小的语义单位

- Lemmatization
- 词规范化的主要方法，主要目标
 - ✓ 用词根来表示词，缩小词汇量
- 语素
 - ✓ 词根 (stems)：承担核心语义的单元
 - ✓ 词缀 (affixes)：附加在词根上，通常承担语法方面的功能
- 词根还原
 - ✓ 剥离词缀，提取词根
 - ✓ 代表性算法：Poster

- 基于人工编制规则，通过连续的5阶段抽取词根
- 例子
 - ✓ ATIONAL → ATE
 - relational → relate
 - ✓ SSES → SS
 - glasses → glass
- 基本符号
 - ✓ c: 表示任意一个辅音字母
 - ✓ v: 表示任意一个元音字母
 - ✓ $\emptyset$: 表示空串
 - ✓ *: 表示重复零次或多次
 - ✓ C: 表示一个或多个辅音字母构成的序列
 - ✓ V: 表示一个或多个元音字母构成的序列

- 一个词表示成(C) (VC)^m (V)形式, 则该词的测度为m
- 例子
 - ✓ tree的词测度为0, 因为 tr (VC)⁰ee
 - ✓ troubles的词测度为1, 因为tr (oubl)¹ (es)
- 规则
 - ✓ 删除复数后缀: $S \rightarrow \emptyset$ (cat~~s~~)
 - ✓ 删除动词形变: $((m > 0) * EED) EED \rightarrow EE$ (agre~~ed~~, feed)
 - ✓ 剥离后缀: $(m > 0) TIONAL \rightarrow TION$ (conditional, rational)
 - ✓ $(m > 0) NESS \rightarrow \emptyset$ (good~~ness~~)
 - ✓ $(m > 1) ENCE \rightarrow \emptyset$ (infer~~ence~~, fence)

- 目标
 - ✓把一段文本中的句子分割出来
- 方法
 - ✓句子的结束符感叹号、问号和句号进行切分。
- 感叹号和问号基本上没问题，句号具有歧义性（对英文等），用于切分句子要注意
 - ✓例如：The period character “.” is ambiguous between a sentence boundary marker and a marker of abbreviations like Mr. or **Inc.**
 - ✓方案：先用规则或机器学习的方法判断 “.” 是缩写的一部分还是句子的结束符
 - 缩写词词典很有帮助

- 功能
 - ✓ 度量两个字符串的差异程度的方法
- 度量方式
 - ✓ 至少需要多少次的处理才能将一个字符串变成另一个字符串
- 应用
 - ✓ 自然语言处理
 - 拼写检查：根据一个拼错的字和正确的字的编辑距离，判断是哪一个正确字的笔误
 - ✓ 生物信息学
 - DNA可视为A、C、G和T组成的字符串。故编辑距离可用于判断两个DNA的相似程度

- 定义

- ✓两个字符串X和Y通过三种编辑操作达到相同所需要的最少操作次数

- 编辑操作

- ✓删除

- AAT~~A~~CTT → AATCTT

- ✓插入

- AATCTT → AAT~~A~~CTT

- ✓替换

- AAT~~C~~TT → AAT~~A~~TT

- 编辑距离 E 具有如下性质
 - ✓ 非负性: $E(S_1, S_2) \geq 0$
 - ✓ 自反性: $E(S_1, S_2) = 0$ 当且仅当 $S_1 = S_2$
 - ✓ 对称性: $E(S_1, S_2) = E(S_2, S_1)$
 - ✓ 三角不等式: $E(S_1, S_3) \leq E(S_1, S_2) + E(S_2, S_3)$
- 以上是距离度量定义所要求的所有四个条件。编辑距离满足距离度量的条件，所以，编辑距离是名副其实的距离

- 令 $E(i, j)$ 表示 X 的第 i 个前缀 $x_1 x_2 \dots x_i$ 与 Y 的第 j 个前缀 $y_1 y_2 \dots y_j$ 的编辑距离

- 基本结论

✓ If $x_i = y_j$, then $E(i, j) = E(i-1, j-1)$

✓ If $x_i \neq y_j$, 则需要对 X 执行以下操作之一


– 用 y_j 替换 x_i : 代价 2 (或 1) + $E(i-1, j-1)$

– 删除 x_i : 代价为 $1 + E(i-1, j)$

– 插入 y_j : 代价为 $1 + E(i, j-1)$

✓ 具体执行上述那个操作, 主要看那个操作带来的代价最小

$E(i-1, j-1)$	$E(i-1, j)$
$E(i, j-1)$	$E(i, j)$



- 令字符串 X 的长度为 n , 字符串 Y 的长度为 m
- 为了计算 $E[i, j]$ (X_i 与 Y_j 的编辑距离), 可以构造 $(n+1) \times (m+1)$ 的2维数组 (矩阵)
- 如下初始化最左边列和最顶部行中的元素
 - ✓ $E(i, 0) = i$ // $x_1 x_2 \dots x_i$ 转换成空串
 - ✓ $E(0, j) = j$ // 空串转换 $y_1 y_2 \dots y_j$
- 为了获取 $E(i, j)$, 只需要三个以前已经获取的值 $E(i-1, j-1), E(i, j-1), E(i-1, j)$ (由基本结论保证)
- 通过递归计算, 能获取 $E(i, j)$
- 最终的结果 $E(n, m)$

- 初始化

- $E(0,0) = 0$; $ptr(i,j) = \text{NULL}$

- 递归计算


- ✓ 第0列和第0行中的元素

$$E(i,0) = E(i-1,0) + 1 \quad \text{删除 } X[i] (x_i)$$

$$E(0,j) = E(0,j-1) + 1 \quad \text{插入 } Y[j] (y_j)$$

- ✓ 其它元素

$$E(i,j) = \min \{ D(i-1,j) + 1, \\ D(i,j-1) + 1, \\ D(i-1,j-1) + \Delta(i,j) \}$$

$$ptr(i,j) = \begin{cases} \text{down,} & \text{if 删除} \\ \text{left,} & \text{if 插入} \\ \text{diagonal,} & \text{if 替换} \end{cases}$$


删除 $X[i] (x_i)$

插入 $Y[j] (y_j)$

$Y[j] (y_j)$ 替换 $X[i] (x_i)$ 或者两者相同

$$\Delta(i,j) = \begin{cases} a, & \text{if } X[i] \neq Y[j] \\ 0, & \text{otherwise} \end{cases}$$

intention $\leftrightarrow$ execution

$$\Delta(i,j) = \begin{cases} 2, & \text{if } X[i] \neq Y[j] \\ 0, & \text{otherwise} \end{cases}$$

Src\Tar	#	e	x	e	c	u	t	i	o	n
#	0	1	2	3	4	5	6	7	8	9
i	1	2	3	4	5	6	7	6	7	8
n	2	3	4	5	6	7	8	7	8	7
t	3	4	5	6	7	8	7	8	9	8
e	4	3	4	5	6	7	8	9	10	9
n	5	4	5	6	7	8	9	10	11	10
t	6	5	6	7	8	9	8	9	10	11
i	7	6	7	8	9	10	9	8	9	10
o	8	7	8	9	10	11	10	9	8	9
n	9	8	9	10	11	12	11	10	9	8

I N T E * N T I O N
 ↓ ↓ ↓ ↓ ↓ ↓ ↓ ↓ ↓
 * E X E C U T I O N

	#	e	x	e	c	u	t	i	o	n
#	0	← 1	← 2	← 3	← 4	← 5	← 6	← 7	← 8	← 9
i	↑ 1	↖←↑ 2	↖←↑ 3	↖←↑ 4	↖←↑ 5	↖←↑ 6	↖←↑ 7	↖ 6	← 7	← 8
n	↑ 2	↖←↑ 3	↖←↑ 4	↖←↑ 5	↖←↑ 6	↖←↑ 7	↖←↑ 8	↑ 7	↖←↑ 8	↖ 7
t	↑ 3	↖←↑ 4	↖←↑ 5	↖←↑ 6	↖←↑ 7	↖←↑ 8	↖ 7	←↑ 8	↖←↑ 9	↑ 8
e	↑ 4	↖ 3	← 4	↖← 5	← 6	← 7	←↑ 8	↖←↑ 9	↖←↑ 10	↑ 9
n	↑ 5	↑ 4	↖←↑ 5	↖←↑ 6	↖←↑ 7	↖←↑ 8	↖←↑ 9	↖←↑ 10	↖←↑ 11	↖↑ 10
t	↑ 6	↑ 5	↖←↑ 6	↖←↑ 7	↖←↑ 8	↖←↑ 9	↖ 8	← 9	← 10	←↑ 11
i	↑ 7	↑ 6	↖←↑ 7	↖←↑ 8	↖←↑ 9	↖←↑ 10	↑ 9	↖ 8	← 9	← 10
o	↑ 8	↑ 7	↖←↑ 8	↖←↑ 9	↖←↑ 10	↖←↑ 11	↑ 10	↑ 9	↖ 8	← 9
n	↑ 9	↑ 8	↖←↑ 9	↖←↑ 10	↖←↑ 11	↖←↑ 12	↑ 11	↑ 10	↑ 9	↖ 8

- 时间



- 空间



- 回溯



- 《Speech and Language Processing》, Chapter 2 “Regular Expressions, Text Normalization, Edit Distance”
- Porter算法内容
 - ✓ 《Modern Information Retrieval》（Ricardo Baeza-Yates 等人著, Addison Wesley 出版）附录
- Porter算法实现
 - ✓ <https://tartarus.org/martin/PorterStemmer/>

统计语言模型