



北京大學

第一讲

课程简介、自然语言理解与语言模型

基于深度学习的自然语言理解

邓志鸿

2025年9月11日星期四



- 课程简介
- 自然语言理解
- 语言模型基础

- 主讲教师

- 邓志鸿

- ✓ 办公室：理科2号楼2318

- ✓ Email: zhdeng@pku.edu.cn

- 助教

- 吴宇桐

- ✓ Email: 2501112184@stu.pku.edu.cn

群聊：2025秋NLU-DL课程群

- 时间

- 周五 7-8节 (15:10-17:00)

- 地点

- 一教203

- 课程网站

- <https://course.pku.edu.cn/>

- 基于深度学习的自然语言理解 (课程号： 04835380)



该二维码7天内(9月17日前)有效，重新进入将更新

- 教材
 - 无
- 参考书
 - 《Speech and Language Processing》 (Daniel Jurafsky and James H. Martin)
✓ <https://probml.github.io/pml-book/book1.html>
 - 《Dive into Deep Learning》 (Aston Zhang, Z. C. Lipton, Mu Li and A. J. Smola)
✓ <https://d2l.ai/>
- 参考教程
 - Natural Language Processing with Deep Learning (Stanford CS 224N)
✓ <https://web.stanford.edu/class/cs224n/index.html>
 - Natural Language Processing (Princeton COS 484)
✓ <https://nlp.cs.princeton.edu/cos484/>

要想及时了解和学习到自然语言理解和处理方面的最新概念与方法、最前沿技术和最新发展动态，以下渠道是不可或缺的

- 国际相关顶级会议
 - ACL, EMNLP, NAACL
 - ICLR, ICML, NeurIPS
 - AAAI, IJCAI
 - 微信公众号
 - 博客、Blog
- } 课程微信群会转发这些平台上的最新报道

- Deepseek
 - ✓ <https://www.deepseek.com/>
- 通义千问（阿里巴巴）
 - ✓ <https://www.tongyi.com/qianwen/>
- 豆包
 - ✓ <https://www.doubao.com/chat/>
- ChatGPT
 - ✓ <https://openai.com/>
- Claude
 - ✓ <https://www.anthropic.com/claude>
- Le Chat
 - ✓ <https://chat.mistral.ai/chat>

注意：本次课程作业和项目基于大模型（不限于以上大模型）的API接口调用

- 数学（基础理论）
 - ✓ 高等数学基础知识（微分）
 - ✓ 线性代数基础知识（向量、矩阵）
 - ✓ 概率基础知识（概率、条件概率等）
- 编程（工程实现）
 - ✓ Pytorch
 - ✓ 其他任何编程语言和平台
- 本课程着重培养通过对开源大模型的API调用来实现各类功能
 - ✓ 可以视为LLM Agent的入门训练
 - ✓ 相对传统编程，入门门槛低很多，很容易掌握

- 帮助同学掌握以深度学习技术为工具的自然语言理解所涉及的基本理论、关键模型、核心算法和前沿技术
 - ✓问题背景
 - ✓建模
 - ✓算法
- 熟悉并掌握大模型时代的编程新范式

- 编程作业 (20%)
 - ✓两个编程练习, 每个占10%
- 论文研读报告 (20%)
 - ✓课堂报告: 10%
 - ✓报告PPT: 10%
- 课程项目 (60%)
 - ✓项目课堂报告 (含PPT制作) : 20%
 - ✓项目质量 (难度、新颖性等) : 40%


A large, light gray starburst graphic with multiple points, serving as a background for the text.

相关安排后续
通知

- 自然语言理解
- N-gram语言模型
- 神经语言模型
- 向量语义与词嵌入
- 循环神经网络
- 条件语言模型、Seq2Seq与注意力机制
- 自注意力与Transformer
- 预训练语言模型
 - ✓ELMo、BERT、T5、GPT 1-4
- 参数高效微调方法
 - ✓Prefix Tuning, Prompt Tuning
 - ✓Adapter Tuning, LoRA, FACT
- In-Context Learning
- 多模态神经语言模型
- 大模型推理

以及上述模型或方法在文本生成、机器翻译、情感分类、自然语言推理、问答系统、对话系统等各类下游任务的应用


文本生成、机器翻译、自动问答、对话、文本摘要、文本/情感分类、文本推理、...




- 课程简介
- 自然语言理解
- 语言模型


- 人工智能的目标之一是实现机器能理解人类语言，从而达到人机无缝交流的目的
- 通过理解语言，可以完成以下任务
 - ✓ 人机对话
 - ✓ 问答
 - ✓ 翻译
 - ✓ 自动摘要
 - ✓ 情感分析
 - ✓ 写作
 - ✓ ...

图灵测试：通过人类和机器之间的自然语言对话来判断机器是否具有智能



- 从自然语言处理发展的四个时代了解自然语言理解的历史
 - ✓ 第一时代 (1950-1969)
 - 最早始于机器翻译的研究，只提供单词级的翻译查找和简单的规则机制
 - ✓ 第二时代 (1970-1992)
 - 语言学和基于知识的人工智能正在迅速发展，出现了新一代手工构建的系统
 - ✓ 第三时代 (1993-2012)
 - NLP的发展逐渐转为深度的语言理解，围绕词开展有监督机器学习技术来构建模型
 - ✓ 第四时代 (2013-现在)
 - 随着深度学习方法的引入，可以对长距离的上下文进行建模。特别是基于自监督学习方法的预训练语言模型/大语言模型带来了变革性的影响，使得自然语言理解 and 处理进入了新的阶段





2018年: BERT 2019年: T5 2020年: GPT 3 2022年: ChatGPT 2023年: GPT-4

把“改革开放以来，北京大学进入了稳步快速发展的新时期，于1994年成为国家“211工程”首批重点建设大学。1998年5月4日，在庆祝北京大学建校一百周年大会上，党中央发出了“为了实现现代化，我国要有若干所具有世界先进水平的一流大学”的号召，之后启动了建设世界一流大学的“985工程”。在这一国家战略的支持和推动下，北京大学的发展翻开了新的一页。”翻译成英文



Since the reform and opening-up, Peking University has entered a new period of steady and rapid development. In 1994, it became one of the first key universities included in the national "211 Project." On May 4, 1998, at the centennial celebration of Peking University, the CPC Central Committee called for "building several world-class universities to advance modernization in China," which led to the launch of the "985 Project" aimed at developing world-leading higher education institutions. With the support and impetus of this national strategy, Peking University opened a new chapter in its development.

给 DeepSeek 发送消息



深度思考 (R1)



联网搜索





信手折枝堪作笔

AI

随心对月可成诗

输入：春 处 夜 花

AI输出：

春风吹雨霏，处处不堪悲。
夜夜深声睡，花开小院垂。

凭栏寄语乡音远

AI

把盏吟诗客梦长

嫩枝粉蕾三分俏

AI

细柳红花一处香

春晓

[唐] 孟浩然

春眠不觉晓，处处闻啼鸟。
夜来风雨声，花落知多少。

《大型语言模型（LLM）原理与应用》课程教学大纲

一、课程基本信息

- **课程名称：**大型语言模型（LLM）原理与应用
- **课程性质：**专业选修课 / 高级研讨课
- **学时/学分：**48学时 / 3学分
- **先修课程：**Python编程、机器学习基础、深度学习、自然语言处理（NLP）导论
- **目标学生：**计算机科学、人工智能、数据科学等相关专业的高年级本科生或研究生

二、课程描述

本课程系统性地介绍大型语言模型（LLM）的核心原理、关键技术、实践方法及前沿应用。课程内容涵盖从Transformer架构的深度学习，到预训练、微调、提示工程等核心技术和应用，同时深入探讨大模型的局限性、伦理问题及未来发展趋势。通过理论学习、论文研读和动手实验，学生将能够理解大模型的工作机制，掌握其应用和优化方法，并具备在该领域进行进一步研究和开发的能力。

三、教学目标

完成本课程后，学生应能够：

1. **理解** Transformer架构及各类大模型（如GPT、BERT、T5等）的核心原理。
2. **掌握** 大模型的预训练、有监督微调（SFT）、奖励模型（RM）与人类反馈强化学习（RLHF）等关键技术。
3. **应用** 提示工程（Prompt Engineering）技术有效利用现有大模型（如ChatGPT、LLaMA等）解决实际问题。
4. **实践** 使用主流框架（如Hugging Face Transformers, LangChain）进行模型的微调与部署。
5. **分析** 大模型的能力、局限性以及相关的伦理、安全和社会影响。

给 DeepSeek 发送消息

深度思考

联网搜索



内容由 AI 生成，请仔细甄别

提供一份大模型课程的教学大纲

四、课程内容与日程安排（共16周）

模块一：引言与基础（2周）

- **第1周：课程概述与LLM导论**
 - 课程介绍、学习目标与考核方式
 - 大型语言模型的发展简史：从统计语言模型到神经网络语言模型，再到LLM
 - LLM的基本概念：参数规模、涌现能力、Scaling Law
 - 当前主流大模型家族概览（OpenAI, Anthropic, Meta, Google, 智谱AI等）
- **第2周：深度学习与NLP基础回顾**
 - 神经网络与梯度下降优化回顾
 - 词嵌入（Word2Vec, GloVe）与上下文嵌入（ELMo）
 - Sequence-to-Sequence模型与注意力机制（Attention Mechanism）简介

模块二：核心架构与预训练（4周）

- **第3周：Transformer架构深析（I）**
 - 自注意力机制（Self-Attention）的数学原理与计算
 - 编码器（Encoder）结构：BERT的基石
 - 掩码自注意力（Masked Self-Attention）与双向编码
- **第4周：Transformer架构深析（II）**
 - 解码器（Decoder）结构：GPT的基石
 - 掩码多头自注意力与因果建模（Causal Modeling）

给 DeepSeek 发送消息

深度思考

联网搜索



内容由 AI 生成，请仔细甄别

有很多根绳子，每一根燃烧的时间都是1小时，如何用这些绳子计算出1小时15分钟？

原理说明：

- **绳子A**：从两端点燃，无论燃烧速度是否均匀，都严格在30分钟内烧尽。
- **绳子B**：
 - 从 $t=0$ 开始一端点燃，燃烧30分钟后（当A烧尽时），剩余时间固定为30分钟（因为总燃烧时间为60分钟）。
 - 点燃另一端后，剩余部分从两端燃烧，烧尽时间固定为剩余时间的一半（ $30\text{分钟} / 2 = 15\text{分钟}$ ），因此B在45分钟时烧尽。
- **绳子C**：从 $t=45\text{分钟}$ （B烧尽时）开始从两端点燃，严格在30分钟内烧尽，结束于 $t=75\text{分钟}$ 。
- 整个过程不依赖绳子的均匀燃烧，只依赖于总燃烧时间和事件（绳子烧尽）的触发。

步骤：

1. 在时间起点 ($t=0$)：

- 同时点燃绳子A的两端和绳子B的一端。
(绳子A从两端燃烧，将在30分钟后完全烧尽；绳子B从一端燃烧，已开始计时。)

2. 当绳子A完全烧尽时 (此时已过去30分钟)：

- 立即点燃绳子B的另一端。
(此时绳子B已燃烧30分钟，剩余燃烧时间为30分钟。点燃另一端后，绳子B从两端燃烧，剩余部分将在15分钟内烧尽，因此绳子B将在45分钟时完全烧尽。)

3. 当绳子B完全烧尽时 (此时已过去45分钟)：

- 立即点燃绳子C的两端。
(绳子C从两端燃烧，将在30分钟后完全烧尽。)

4. 当绳子C完全烧尽时：

- 此时正好过去了75分钟（45分钟 + 30分钟 = 75分钟），即1小时15分钟。

关公拿起手机给秦琼发了各短信，约定在纽约大战一场，一决胜负。以上这句话有问题吗？

这句话有问题，主要体现在以下几个方面：

- **历史时空错乱**：关公即关羽，是东汉末年三国时期的人物；秦琼是隋末唐初的人物，二人所处时代不同，相差数百年，不可能直接联系。而且他们都是中国古代人物，与现代的纽约在时空上完全不搭界，让他们在纽约大战违背了基本的历史和地理常识。
- **人物行为不符**：关公和秦琼都是古代的武将，生活在冷兵器时代，对现代的手机、短信等通讯工具毫无概念，也不可能使用这些现代科技产品来约定战斗。
- **地点选择不合理**：纽约是现代美国的一座国际化大都市，与关公、秦琼所处的古代背景毫无关联，将他们的战斗场景设定在纽约，显得十分荒诞和不切实际。

这句话存在诸多与历史事实和现实逻辑相违背的地方，是一种夸张、虚构且不符合常理的表述，多用来形容一些不切实际或荒诞不经的想象。

🔊 📄 ↺️ ↻️ 分享 ... | 👍 🗨️

🖼️ 图像生成

📝 帮我写作

🔍 AI 搜索

📖 AI 阅读

💻 AI 编程

🌐 翻译

🔍 学术搜索

🔗 更多

发消息、输入 @ 选择技能或 / 选择文件

🧠 深度思考

🔗 📄 ✂️ 🗣️ | ⬆️



根据您的偏好，这里为您规划一个三天的北京小众旅游路线，旨在探索那些拥有丰富人文历史背景且游客相对较少的地方。

第一天：探访古村落与自然景观

- **上午：**前往门头沟区的潭柘寺。这是一座历史悠久的佛教寺庙，始建于西晋时期，以其悠久的历史 and 宁静的环境著称。
 - 您可以在这里体验到古刹的庄严肃穆，同时享受远离城市喧嚣的宁静。
- **中午：**在门头沟区内享用午餐，尝试一些当地的农家菜。
- **下午：**参观爨底下村，这是一个保存完好的明清古村落，位于山区之中，风景秀丽，人烟稀少。
 - 在村里漫步，欣赏古老的四合院建筑，感受古代的生活气息。
- **晚上：**可以选择住在爨底下村的民宿，体验乡村夜晚的静谧。

第二天：探索历史遗迹与文化景点

- **上午：**驱车前往房山区的周口店北京人遗址博物馆，这里是“北京猿人”的发现地，对于了解人类起源有着重要意义。
 - 参观博物馆，了解史前人类的生活方式和考古发掘过程。
- **中午：**在当地餐馆享用午餐，尝试房山特色菜肴。
- **下午：**游览云居寺，这是一座千年古刹，以其石刻佛经闻名于世。
 - 在寺庙内漫步，欣赏精美的石刻艺术，感受浓厚的宗教氛围。
- **晚上：**返回市区，在后海或南锣鼓巷一带寻找一家安静的茶馆，享受悠闲的夜晚。

在这里和我对话

服务生成的所有内容均由人工智能模型生成，其生成内容的准确性和完整性无法保证，不代表我们的态度或观点

我在北京旅游，大概停留3天左右。我比较喜欢人少但又有人文、历史和美景的旅游景点，请推荐一条线路。

第三天：京郊的隐秘美景

- **全天：**前往怀柔区的黄花城水长城，这是一个融合了自然美景和历史文化的地方，游客相对较少。
 - 徒步穿越水长城，沿途欣赏山水相依的美丽风光，还可以选择在湖边划船，享受轻松的一天。
- **午餐：**自带简单的野餐食物，或者在当地找到合适的餐馆。
- **晚上：**回到市区，结束愉快的旅程，可以选择一家有特色的餐厅庆祝这次旅行的成功。

这条路线不仅能让您深入了解北京的人文历史，还能让您享受到较为宁静的旅游环境。记得提前查询各景点的开放时间和门票信息，并做好相应的准备。希望您在北京有一个难忘的旅行经历！



a car is parked in the middle of nowhere .



a wooden table and chairs arranged in a room .



there is a cat sitting on a shelf .



a little boy with a bunch of friends on the street .



a ferry boat on a marina with a group of people .

看图说话

跨模态检索

Nearest Images



- day + night =

- flying + sailing =

- bowl + box =

- box + bowl =



文生图

席地而坐看星空的小孩和小狗

生成



一幅近景的柔和野兽派绘画，描绘了一个年轻夫妇手牵手在巴黎拥挤的小巷中漫步。天空下着毛毛细雨，湿漉漉的鹅卵石街道映照出周围的建筑物。藤蔓优雅地垂挂在建筑物的侧面，露天酒吧里坐满了顾客，其中一些人凝视着外面，享受雨水的宁静。在背景中可以隐约看到埃菲尔铁塔的轮廓。

生成



User

What is unusual about this image?



Source: <https://www.barnorama.com/wp-content/uploads/2016/12/03-Confusing-Pictures.jpg>

GPT-4

The unusual thing about this image is that a man is ironing clothes on an ironing board attached to the roof of a moving taxi.

画一幅武松打虎的图画

好的，我将为您生成武松打虎的图画。考虑到这一经典场景的力量感与戏剧性，我会采用 Frank Frazetta 的插画风格，他擅长通过强烈的明暗对比和动态构图展现英雄主义题材。画面将聚焦武松与老虎的激烈搏斗瞬间，突出双方的力量碰撞与紧张氛围。



画一幅武松打虎的卡通画

好的，我将为您生成一幅武松打虎的卡通画。我会采用迪士尼经典动画风格，这种风格色彩明快，人物造型圆润富有亲和力，适合展现故事的动感与趣味性。



画一幅武松打狮子的图画

好的，我将为您创作一幅武松打狮子的图画。考虑到这一题材的力量感与戏剧性，我会采用 Frank Frazetta 的奇幻插画风格，这种风格以强烈的动态构图和浓郁的色彩著称，非常适合表现英雄与猛兽的激烈对抗。



画一幅武松打狮子的图画，注意体现狮子的生活环境

好的，我将为您生成一幅武松与狮子搏斗的图画，采用充满张力的写实油画风格，着重刻画非洲草原的自然生态环境。



- 课程简介
- 自然语言理解
- 语言模型


- 背景
- 基本概念
- N-gram语言模型
- 概率参数估计
- 评估
- 文本生成
- 概率修正
- 讨论

- 如何判断一个句子是对的，是能够被大家理解的

- ✓ 我现在必须离开
- ✓ 我必须离开现在
- ✓ 离开我必须现在

- 众多自然语言处理任务的基础

- ✓ 机器翻译
- ✓ 对话
- ✓ 问答
- ✓ ...



- 语言模型 (Language Model)

- ✓ 计算词序列或句子的概率，通过句子的生成概率来理解和分析句子

- ✓ 也称概率语言模型 (Probabilistic Language Model)

- 形式化定义

- ✓ 给定词序列或句子 $S = t_1 t_2, \dots t_L$ ，其中 $t_i \in V$ (词汇表)

- ✓ 语言模型的目标：给出 $P(S)$ 的计算方法，即计算

$$P(t_1, t_2, \dots, t_L)$$

确切的说，应该是token。
Token可以是词、词组、字、
甚至是字母、标点符号等

- 扩展的乘法公式

$$P(t_1, t_2, \dots, t_L) = \prod_{l=1}^L P(t_l | t_1, t_2, \dots, t_{l-1})$$

- 因此，语言模型本质是要计算条件概率

$$P(t_l | t_1, t_2, \dots, t_{l-1})$$

$$P(t | \text{小猫, 爬}) = \begin{cases} 0.7, t = \text{树} \\ 0.2, t = \text{墙} \\ 0.001, t = \text{山} \\ \vdots \end{cases}$$

- ✓这实际上是计算给定前几个词，预测下一个词出现的概率

- ✓可以理解为语言模型就是对上述条件概率建模，即如何计算上述条件概率

- ✓注意：文本生成的理论基础


- 根据计算条件概率的方式，语言模型可以分为以下两大类

- ✓统计语言模型

$$P(t_l = t | t_1, t_2, \dots, t_{l-1}) = \frac{P(t_1, t_2, \dots, t_{l-1}, t)}{P(t_1, t_2, \dots, t_{l-1})} \approx \frac{\text{Count}(t_1, t_2, \dots, t_{l-1}, t)}{\text{Count}(t_1, t_2, \dots, t_{l-1})}$$

- N-gram语言模型

- ✓神经网络语言模型



- 循环神经网络

- 基于Transformer的各类预训练语言模型

- 问题

✓假定词序列长度为 L ，词汇量 $|V| = n$ ，且词序列可含重复的词

$$P(t_1) = \frac{\text{Count}(t_1)}{\sum_{t \in V} \text{Count}(t)}$$

n 个概率

$$P(t_2|t_1) = \frac{\text{Count}(t_1, t_2)}{\text{Count}(t_1)}$$

n^2 个概率

$\vdots$

$\vdots$

$$P(t_L|t_1, t_2, \dots, t_{L-1}) = \frac{\text{Count}(t_1, t_2, \dots, t_{L-1}, t_L)}{\text{Count}(t_1, t_2, \dots, t_{L-1})}$$

n^L 个概率



$$\sum \frac{n^{L+1} - 1}{n - 1}$$

$$n = 10000$$

$$L = 10$$

- k 阶马尔可夫假设

- ✓ $P(t_l | t_1, t_2, \dots, t_{l-1}) = P(t_l | t_{l-k}, t_{l-k+1}, \dots, t_{l-1})$

- ✓ 即当前词出现的概率只与其前的 k 个词有关，与再之前的词无关（独立）

- ✓ 例如：在一阶马尔可夫假设下 $P(\text{树} | \text{小猫}, \text{爬}) = P(\text{树} | \text{爬})$

- 因此

$$P(t_l | t_1, t_2, \dots, t_{l-1}) = P(t_l | t_{l-k}, t_{l-k+1}, \dots, t_{l-1})$$

$$= \frac{\text{Count}(t_{l-k}, t_{l-k+1}, \dots, t_{l-1}, t_l)}{\text{Count}(t_{l-k}, t_{l-k+1}, \dots, t_{l-1})}$$

控制 k ，就可以控制所需
计算的条件概率数量

- Unigram 模型

$$\checkmark P(t_l | t_1, t_2, \dots, t_{l-1}) = P(t_l)$$

$$\checkmark P(t_1, t_2, \dots, t_L) = \prod_{l=1}^L P(t_l)$$

- Bigram 模型

$$\checkmark P(t_l | t_1, t_2, \dots, t_{l-1}) = P(t_l | t_{l-1})$$

$$\checkmark P(t_1, t_2, \dots, t_L) = \prod_{l=1}^L P(t_l | t_{l-1})$$

- N-gram 模型

$$\checkmark P(t_l | t_1, t_2, \dots, t_{l-1}) = P(t_l | t_{l-n+1}, \dots, t_{l-1})$$

$$\checkmark P(t_1, t_2, \dots, t_L) = \prod_{l=1}^L P(t_l | t_{l-n+1}, \dots, t_{l-1})$$

- 以经典的Bigram语言模型为例，介绍统计语言模型的参数（概率）计算过程
- 模型参数
 - ✓ $P(t_l|t_{l-1})$
- 参数估计
 - ✓ 给定语料库，通过以下统计计算方式估计条件概率

$$P(t_l|t_{l-1}) = \frac{\text{Count}(t_{l-1}, t_l)}{\text{Count}(t_{l-1})}$$

$t_{l-1}t_l$ 在语料库出现次数

t_{l-1} 在语料库出现次数

- 语料库

- <s>小王看见一只小猫爬树</s>
- <s>小猫爬树</s>
- <s>一只啄木鸟在啄树</s>
- <s>小猫打架</s>
- <s>我爬山了</s>

分词

- 语料库

- <s> 小王 看见 一只 小猫 爬 树 </s>
- <s> 小猫 爬 树 </s>
- <s> 一只 啄木鸟 在 啄树 </s>
- <s> 小猫 打架 </s>
- <s> 我 爬 山 了 </s>

- 语料库

- <s> 小王 看见 一只 小猫 爬 树 </s>
- <s> 小猫 爬 树 </s>
- <s> 一只 啄木鸟 在 啄树 </s>
- <s> 小猫 打架 </s>
- <s> 我 爬 山 了 </s>

Bigram



<s> 小王; 小王 看见; 看见 一只; 一只 小猫; 小猫 爬; 爬 树; 树 </s>
<s> 小猫; 小猫 爬; 爬 树; 树 </s>
<s> 一只; 一只 啄木鸟; 啄木鸟 在; 在 啄; 啄树</s>
<s> 小猫; 小猫 打架; 打架 </s>
<s> 我; 我 爬; 爬 山; 山 了; 了 </s>

<s> 小王; 小王 看见; 看见 一只; 一只 小猫; 小猫 爬; 爬 树; 树 </s>

<s> 小猫; 小猫 爬; 爬 树; 树 </s>

<s> 一只; 一只 啄木鸟; 啄木鸟 在; 在 啄; 啄树</s>

<s> 小猫; 小猫 打架; 打架 </s>

<s> 我; 我 爬; 爬山; 山了; 了 </s>

$$P(\text{小猫} | \text{< s >}) = \frac{\text{Count}(\text{< s > 小猫})}{\text{Count}(\text{< s >})} = \frac{2}{5}$$

$$P(\text{树} | \text{啄}) = \frac{\text{Count}(\text{啄树})}{\text{Count}(\text{啄})} = \frac{1}{1} = 1$$

$$P(\text{爬} | \text{小猫}) = \frac{\text{Count}(\text{小猫爬})}{\text{Count}(\text{小猫})} = \frac{2}{3}$$

$$P(\text{树} | \text{爬}) = \frac{\text{Count}(\text{爬树})}{\text{Count}(\text{爬})} = \frac{2}{3}$$

$$P(\text{啄} | \text{小猫}) = \frac{\text{Count}(\text{小猫啄})}{\text{Count}(\text{小猫})} = \frac{0}{3} = 0$$

$$P(\text{树} | \text{</s>}) = \frac{\text{Count}(\text{树</s>})}{\text{Count}(\text{</s>})} = \frac{1}{5}$$

小猫爬树 $\rightarrow$ $\langle s \rangle$ 小猫 爬 树 $\langle /s \rangle$

小猫啄树 $\rightarrow$ $\langle s \rangle$ 小猫 啄 树 $\langle /s \rangle$

$$P(\langle s \rangle \text{ 小猫 爬 树 } \langle /s \rangle) = P(\text{小猫} | \langle s \rangle) P(\text{爬} | \text{小猫}) P(\text{树} | \text{爬}) P(\text{树} | \langle /s \rangle) = \frac{2}{5} \times \frac{2}{3} \times \frac{2}{3} \times \frac{1}{5} = \frac{8}{225} \quad \checkmark$$

$$P(\langle s \rangle \text{ 小猫 啄 树 } \langle /s \rangle) = P(\text{小猫} | \langle s \rangle) P(\text{啄} | \text{小猫}) P(\text{树} | \text{啄}) P(\text{树} | \langle /s \rangle) = \frac{2}{5} \times 0 \times \frac{2}{3} \times \frac{1}{5} = 0 \quad \times$$

- 基于计数统计的参数估计方法很直观，很朴素

$$P(t_l|t_{l-1}) = \frac{Count(t_{l-1}, t_l)}{Count(t_{l-1})}$$

- 问题

- ✓这个参数估计方法有没有理论上的支持，它背后隐含着什么样的科学依据

- 利用最大似然估计方法，可以回答以上问题，推导出以上参数估计方法

- ✓上述估计出的条件概率，能保证在Bigram语言模型下，语料库出现（生成）的概率最大

- 语言模型是否倾向于好句子还是差句子
 - ✓ 赋予“频繁被观测到的”或“真实的”句子更高概率
 - ✓ 而不是“语法不对的”或“很难被观测到的”句子
- 模型参数源自训练语料
- 为公平起见，在测试集上测试和评估
 - ✓ 测试集与训练语料不同，在训练模型时没用到过
 - ✓ 指定可以鉴别模型好坏的度量方法

- 外部评估

- ✓把语言模型A和B应用到具体的自然语言处理任务中
 - 拼写纠错、机器翻译，问答等
- ✓测试具体任务，得到模型A和B在该任务上准确性，以此为基准评价模型的优劣
 - 多少词翻译正确
- ✓缺点：比较耗时

- 内部评估

- ✓以困惑度 (perplexity) 为指标，度量模型在测试语料上的性能
 - 一般假定测试语料与训练语料同分布
- ✓虽然不完美，但在中试阶段有价值

- 直观理解

- ✓猜字游戏（香农游戏， Shannon Game ）

- 我通常订带有奶酪和蔬菜的__？

- 中国的首都是__？

- 我看见了一匹__？

- ✓显然Unigram模型在猜字游戏中难于有好的表现。为什么？

- 好的语言模型

- ✓应该给实际出现的词予以更高概率

披萨	0.1
面包	0.1
意大利面	0.05
....	
热干面	0.0001
....	

- 好的语言模型能很好预测未见到的文本

- ✓对未见到的文本给出高的概率值

- 困惑度定义

- ✓给定文本 $S = t_1 t_2 \dots t_L$, 语言模型 LM 在其上的困惑度定义为

$$PPL(S, LM) = P(t_1, t_2, \dots t_L)^{-\frac{1}{L}}$$

- 其中 $P(t_1, t_2, \dots t_L)$ 是语言模型 LM 给出 S 的概率

- 最小化困惑度等同于最大化生成概率

- ✓困惑度越小, 语言模型越好

$$PPL(S, LM) = P(t_1, t_2, \dots, t_L)^{-\frac{1}{L}} = \sqrt[L]{\frac{1}{P(t_1, t_2, \dots, t_L)}} = \sqrt[L]{\prod_{l=1}^L \frac{1}{P(t_l | t_1, \dots, t_{l-1})}}$$

如果 LM 是bigram语言模型, 则 $PPL(S, LM) = \sqrt[L]{\prod_{l=1}^L \frac{1}{P(t_l | t_{l-1})}}$

在三千八百万单词的WSJ数据集训练语言模型后, 在含一百五十万单词的测试集上的结果

	Unigram	Bigram	Trigram
困惑度	962	170	109

- 假定n-gram语言模型的条件概率定义如下


$$P(t_l | t_{l-n+1}, \dots, t_{l-1}) = \frac{1}{|V|}$$

$$PPL(S, LM) = \sqrt[L]{\prod_{l=1}^L \frac{1}{P(t_l | t_{l-n+1}, \dots, t_{l-1})}} = |V|$$

度量语言模型预测下一个词的不确定性，
困惑度越大，预测的不确定性越大

- 给定一个Bigram语言模型（或其他N-gram语言模型），可通过采样技术生成句子 $P_{ij} = P(v_i|v_j)$

- ✓根据概率分布 $P(v|<s>)$ 采样第一个单词：我们
- ✓根据概率分布 $P(v|我们)$ 采样第二个单词：是
- ✓根据概率分布 $P(v|是)$ 采样第三个单词：大学生
- ✓根据根据概率分布 $P(v|大学生)$ 采样第四个单词：</s>



N-gram语言模型生成文本实例

1
gram

–To him swallowed confess hear both. Which. Of save on trail for are ay device and rote life have
–Hill he late speaks; or! a more to leg less first you enter

2
gram

–Why dost stand forth thy canopy, forsooth; he is this palpable hit the King Henry. Live king. Follow.
–What means, sir. I confess she? then all sorts, he is trim, captain.

3
gram

–Fly, and will rid me these news of price. Therefore the sadness of parting, as they say, 'tis done.
–This shall forbid it should be branded, if renown made it empty.

4
gram

–King Henry. What! I will go seek the traitor Gloucester. Exeunt some of the watch. A great banquet serv'd in;
–It cannot be but so.

- N-grams语言模型只统计训练语料中出现的grams的信息，并没有未出现在训练预料中的grams的统计信息，从而对未出现在训练预料中的grams不能有效处理和预测
 - ✓实际可能的grams要远多于训练语料中的grams
 - 以莎士比亚文集为例，其包含近三万个词，包含大约三十万bigrams。可能的bigrams有超过八亿个
 - ✓很多条件概率值为零，这极大限制了N-grams语言模型的泛化能力，即在未见过的文本上的性能
- 对零值概率进行修正，使其成为非零值

9332个句子，词汇量1446

i	want	to	eat	chinese	food	lunch	spend
2533	927	2417	746	158	1093	341	278

	i	want	to	eat	chinese	food	lunch	spend
i	5	827	0	9	0	0	0	2
want	2	0	608	1	6	6	5	1
to	2	0	4	686	2	0	6	211
eat	0	0	2	0	16	2	42	0
chinese	1	0	0	0	0	82	1	0
food	15	0	15	0	1	4	0	0
lunch	2	0	0	0	0	1	0	0
spend	1	0	1	0	0	0	0	0

$$P(i|i) = \frac{5}{2533} \approx 0.002$$

$$P(want|i) = \frac{827}{2533} \approx 0.33$$

$$P(spend|i) = \frac{2}{2533} \approx 0.00079$$

$$P(chinese|spend) = \frac{0}{278} = 0$$

	i	want	to	eat	chinese	food	lunch	spend
i	0.002	0.33	0	0.0036	0	0	0	0.00079
want	0.0022	0	0.66	0.0011	0.0065	0.0065	0.0054	0.0011
to	0.00083	0	0.0017	0.28	0.00083	0	0.0025	0.087
eat	0	0	0.0027	0	0.021	0.0027	0.056	0
chinese	0.0063	0	0	0	0	0.52	0.0063	0
food	0.014	0	0.014	0	0.00092	0.0037	0	0
lunch	0.0059	0	0	0	0	0.0029	0	0
spend	0.0036	0	0.0036	0	0	0	0	0

- Training set:

... denied the allegations
 ... denied the reports
 ... denied the claims
 ... denied the request

- Test set

... denied the offer
 ... denied the loan

$$P(\text{offer} \mid \text{denied the}) = 0$$

- 平滑法 (smoothing)
 - ✓ 通过加虚拟的“伪计数”来调整概率，词的频次和总频次都增加
 - ✓ 有理论基础支持
 - ✓ 代表性方法：拉普拉斯平滑、利德斯通平滑
- 折扣法 (Discounting)
 - ✓ 直接调整概率，但词的频次和总频次保存不变
 - ✓ 代表性方法：绝对折扣法
- 其他方法
 - ✓ 用低阶语言模型信息来补充或修改高阶语言模型的参数
 - ✓ 代表性方法：回退法 (Backoff)、插值法 (Interpolation)

- Laplace Smoothing, 也称加1估计 (Add-one estimation)
- 最大似然估计

$$P(v_i|v_j) = \frac{\mathbf{Count}(v_j v_i)}{\mathbf{Count}(v_j)}$$

- 拉普拉斯平滑

$$P(v_i|v_j) = \frac{\mathbf{Count}(v_j v_i) + 1}{\mathbf{Count}(v_j) + |V|}$$

	i	want	to	eat	chinese	food	lunch	spend
i	6	828	1	10	1	1	1	3
want	3	1	609	2	7	7	6	2
to	3	1	5	687	3	1	7	212
eat	1	1	3	1	17	3	43	1
chinese	2	1	1	1	1	83	2	1
food	16	1	16	1	2	5	1	1
lunch	3	1	1	1	1	2	1	1
spend	2	1	2	1	1	1	1	1

$$P(t_l|t_{l-1}) = \frac{\mathbf{Count}(t_{l-1}, t_l) + 1}{\mathbf{Count}(t_{l-1}) + |V|} \quad |V| = 1446$$

$$P(to|i) = \frac{\mathbf{Count}(i \ to) + 1}{\mathbf{Count}(i) + 1446} = \frac{0 + 1}{2533 + 1446} \approx 0.00025$$

	i	want	to	eat	chinese	food	lunch	spend
i	0.0015	0.21	0.00025	0.0025	0.00025	0.00025	0.00025	0.00075
want	0.0013	0.00042	0.26	0.00084	0.0029	0.0029	0.0025	0.00084
to	0.00078	0.00026	0.0013	0.18	0.00078	0.00026	0.0018	0.055
eat	0.00046	0.00046	0.0014	0.00046	0.0078	0.0014	0.02	0.00046
chinese	0.0012	0.00062	0.00062	0.00062	0.00062	0.052	0.0012	0.00062
food	0.0063	0.00039	0.0063	0.00039	0.00079	0.002	0.00039	0.00039
lunch	0.0017	0.00056	0.00056	0.00056	0.00056	0.0011	0.00056	0.00056
spend	0.0012	0.00058	0.0012	0.00058	0.00058	0.00058	0.00058	0.00058

- Lidstone Smoothing
- 这类平滑技术相当于加了一个虚拟的“伪计数”，避免出现概率值为零

$$P(v_i|v_j) = \frac{\mathbf{Count}(v_j v_i) + \alpha}{\mathbf{Count}(v_j) + \alpha|V|}$$

✓ $\alpha=1$, 拉普拉斯平滑

✓ $\alpha=0.5$, 在实际应用中效果很好



- 用贝叶斯方法来估计概率参数

$$\begin{aligned}
 \mathbf{x} &= \{x_i\}, x_i \triangleq P(v_i|v_j) \\
 \mathbf{x} \sim \text{Dir}(\boldsymbol{\alpha}) &= \frac{1}{B(\boldsymbol{\alpha})} \prod x_i^{\alpha_i-1} \quad + \quad \begin{array}{c} \text{句子集合} \\ \mathcal{D} \end{array} \quad \longrightarrow \quad P(\mathbf{x}|\mathcal{D}) = \frac{P(\mathcal{D}|\mathbf{x})P(\mathbf{x})}{P(\mathcal{D})} \sim \text{Dir}(\tilde{\boldsymbol{\alpha}}) \\
 \boldsymbol{\alpha} &= \{\alpha_i = \alpha\} \qquad \qquad \qquad \tilde{\boldsymbol{\alpha}} = \{\tilde{\alpha}_i\}
 \end{aligned}$$

$$\tilde{\alpha}_i = \text{Count}(v_j v_i) + \alpha$$

$$\begin{aligned}
 E[x_i|\mathcal{D}] &= \frac{\tilde{\alpha}_i}{\sum_k \tilde{\alpha}_k} = \frac{\text{Count}(v_j v_i) + \alpha}{\sum_k (\text{Count}(v_j v_k) + \alpha)} = \frac{\text{Count}(v_j v_i) + \alpha}{\sum_k \text{Count}(v_j v_k) + \alpha|V|} \\
 &= \frac{\text{Count}(v_j v_i) + \alpha}{\text{Count}(v_j) + \alpha|V|}
 \end{aligned}$$

- 估计 $P(w|denied\ the)$
 - ✓ 7个词, 在 $denied\ the$ 后面出现的次数为
 - Allegations: 3
 - reports: 2
 - claims: 1
 - request: 1
 - attack, man, outcome: 0
- 每个出现次数大于1的词贡献0.09的次数, 均分给未出现的词
 - ✓ 修正出现次数
 - Allegations: 2.91
 - reports: 1.91
 - claims: 0.91
 - request: 0.91
 - attack, man, outcome: 0.12



			Lidstone smoothing, $\alpha = 0.1$	Discounting, $d = 0.1$
	counts	unsmoothed probability	smoothed probability	smoothed probability
<i>impropriety</i>	8	0.4	0.391	0.395
<i>offense</i>	5	0.25	0.246	0.245
<i>damage</i>	4	0.2	0.198	0.195
<i>deficiencies</i>	2	0.1	0.101	0.095
<i>outbreak</i>	1	0.05	0.053	0.045
<i>infirmity</i>	0	0	0.005	0.013
<i>cephalopods</i>	0	0	0.005	0.013

- 卡茨回退法 (Katz backoff)

$$P(v_l|v_{l-n}, \dots, v_{l-1}) = \begin{cases} P^*(v_l|v_{l-n}, \dots, v_{l-1}), & \text{if } \text{Count}(v_{l-n}, \dots, v_l) > 0 \\ \alpha(v_{l-n}, \dots, v_{l-1})P(v_l|v_{l-n+1}, \dots, v_{l-1}), & \text{otherwise} \end{cases}$$

- 以bigram模型为例

$$P(v_i|v_j) = \begin{cases} \frac{\text{Count}^*(v_j v_i)}{\text{Count}(v_j)}, & \text{if } \text{Count}(v_j v_i) > 0 \\ \alpha(v_j) \times \frac{P(v_i)}{\sum_{v: \text{Count}(v_j v)=0} P(v)}, & \text{otherwise} \end{cases}$$

折扣

$$\text{Count}^*(v_j v_i) = \text{Count}(v_j v_i) - d$$

参数，可以调节以获得好的性能


- Interpolation

- ✓通过线性组合低阶语言模型来实现高阶语言模型

- 以Trigram为例


$$\hat{P}(v_t|v_{t-2}, v_{t-1}) = \lambda_1 P(v_t|v_{t-2}, v_{t-1}) + \lambda_2 P(v_t|v_{t-1}) + \lambda_3 P(v_t)$$

超参数



其中： $\lambda_1 + \lambda_2 + \lambda_3 = 1$ Why?

- 如何选择超参数 $\lambda_1, \lambda_2, \lambda_3$
 - ✓ 首先在训练集上估计概率参数
 - ✓ 选择超参数，使得验证集的生成概率最大
 - ✓ 在测试集上评估以上得到的最好模型



- 未收录词 (Unknown Words) 如何处理?

$$\checkmark v \notin V$$

- 统计语言模型（N-gram语言模型）的不足

- ✓

- ✓

- ✓

神经语言模型与词嵌入